

基于机器学习的微博用户主观幸福感评估工具开发及其心理学意义：一项评价性与解释性研究

摘要

基于语言评估主观幸福感，既需要考察预测与自我报告的关联，也需要检验分数估计的准确性。本研究使用 1,037 名微博用户的 120 个心理语言特征，分别预测消极情绪、积极情绪和生活满意度。在开发集中通过五折交叉验证比较八类模型，并保留 104 名参与者用于评估。选定的共享随机森林与三个结局的相关系数依次为 0.247、0.284 和 0.152，均方根误差依次为 0.166、0.165 和 0.202，单位为存储分数单位。两种情绪的相关经 Holm 校正后仍显著，生活满意度的相关区间则包含零。相对训练均值基线的误差降幅较小，预定配对比较未达到多重比较校正标准；所选共享森林相对独立森林也未显示明确优势。记录选择和特征排除的敏感性分析保留了总体预测模式。后续探索性优化未改善嵌套开发集表现。开发集特征归因较高的类别，在留出集中的置换误差变化较小且方向不一。结果表明，微博语言包含与情绪有关的有限回溯性信息，但转化为分数估计的收益较小。进一步开发评估工具，需要核实计分方式、对齐语言与效标的时间，并针对明确用途检验准确性和稳定性。

关键词：主观幸福感；心理语言学；微博；预测误差；多输出回归；模型解释

利益冲突：待作者提供声明。

引言

评估主观幸福感，关注的是人们如何体验和评价自己的生活。积极情绪、消极情绪和生活满意度分别反映情绪体验与对整体生活的认知评价 (Diener, 1984)。积极与消极情绪量表 (PANAS) 和生活满意度量表 (SWLS) 通过不同的自我报告指标测量这些成分 (Diener et al., 1985; Watson et al., 1988)。因此，从语言中推导出的分数，需要保留与相应成分有关的信息，仅仅识别表面上积极或消极的词语并不足够。参与者对自身体验的报告，构成检验这种推断的效标 (Diener et al., 2018)。

社交媒体帖子提供了一种表达记录，可以与主观体验报告相联系，而不要求用户在每条帖子中直接描述自己的幸福感。其潜在价值在于为直接评估之间的时段补充信息。基于语言的人格评估研究展示了如何检验这一设想：Park et al. (2015) 考察了语言分数与自我报告、知情者报告的聚合关系、不同人格特质之间的区分、外部关联以及时间稳定性。这些证据来自英语 Facebook 语言中的人格评估。对于中文微博上的幸福感估计，需要进一步回答的问题是：特定语言表征保留了多少与各个问卷结局有关的信息，以及这些信息能否改善参与者分数的估计。

心理语言词典通过预定义类别概括语言，使上述问题具备可操作的研究形式。这些类别为模型解释提供了可辨认的内容领域，同时也将不同语境中的用词合并在一起。语境、反讽和习语均可能改变一个词典匹配所具有的心理含义 (Tausczik & Pennebaker, 2010)。在中文社交媒体文本中，Zhao et al. (2016) 发现，简体中文 LIWC 分数与人工判断的一致程度因类别而异；相较于检出类别词语，判断单条帖子的心理含义更加困难。因此，词典类别可以作为幸福感的候选预测变量，但其表征是否充分，仍需要通过参与者层面的结局加以检验。

既有幸福感研究进一步说明，评估的分析单位至关重要。Jaidka et al. (2020) 发现，英语用词的地域和社会经济差异会干扰基于词典的美国县域幸福感估计；该研究在 Facebook 用户中的个体层面比较，也呈现出不同于县域分析的关联模式。这些发现提示，应当在目标人群和目标分析单位上检验语言表征，不能将其效应量直接视为微博个体预测的预期表现。封闭词汇与开放词汇方法的比较同样表明，预定义类别与更具体的语言模式提供了不同的信息来源 (Eichstaedt et al., 2021)。本研究据此评估给定类别表征的预测表现，而不预先假定具有心理含义的类别名称就能保证准确的心理评估。

幸福感各成分之间的关联还提出了一个建模问题：应当共同学习，还是分别学习它们与语言的关系？共享表征可以利用相关任务提供的归纳偏置 (Caruana, 1997)。在多输出树中，各个结局共用同一套特征空间划分，并输出一个预测向量；独立树则允许每个结局形成自己的划分 (Kocev et al., 2007)。当有用的划分相互重合时，共享可能降低估计的波动；独立建模则保留了各成分特有的关系。结局间的相关性使这一比较具有研究意义，但共享是否有助于预测，取决于特征与各结局之间的具体关系。其收益需要在未参与模型开发的参与者上进行检验 (Yarkoni & Westfall, 2017)。

本研究使用既有微博数据集考察三个问题：聚合心理语言特征能够在多大程度上估计留出参与者的消极情绪、积极情绪和生活满意度；由开发集选出的共享输出程序，是否优于独立拟合程序；以及哪些类别对选定树模型的预测作出了贡献。第一个问题同时使用 Pearson 相关和相对训练均值基线的预测误差进行评价。相关描述线性共变，误差则反映预测分数与观察分数的接近程度。第二个问题通过所选程序之间的配对比较回答。第三个问题结合开发集归因和留出集扰动诊断进行分析。这些分析将语言是否包含相关信息，与这些信息能够多好地支持分数估计联系起来。

方法

参与者与数据采集

原始数据采集说明记载，研究通过向约 20,000 名微博用户发送私信邀请进行便利招募。参与者提供知情同意，并一次性、不间断地完成在线问卷，随后研究者通过新浪微博 API 获取其公开帖子和个人资料。纳入条件排除了未满 18 岁、没有公开账号、未提供同意或问卷作答中断的用户。完成者获得金钱奖励。说明将数据采集与一个于 2012 年九月至 2013 年二月开展的平行项目相联系，但本数据文件对应的确切招募日期尚未核实。本次二次分析使用提供的参与者层面特征和分数，未招募新的参与者。

原始输入包含 1,427 行数据，对应 1,037 名参与者。其中，195 名参与者各有两条不同的观察记录，以及其中一条记录的完全相同副本。我们删除了 195 行精确重复记录，并为每名参与者保留数值型问卷时间戳最小的观察。不同观察在最早时间戳上没有并列。由此得到的 1,037 条记录使每名参与者在模型开发和评估中具有相同的权重；其他记录选择方式通过敏感性分析考察。由于时间戳的编码和重复观察的来源未被完整记录，本研究采用时间戳的数值顺序。人口学变量、问卷题目及招募中间阶段的人数均不可用。

数据采集说明报告了知情同意、自愿参与、退出权利和机构伦理审查批准。具有机构识别信息的批准详情列于独立标题页。负责作者仍需确认原始批准与同意文件、本次二次分析的授权，以及数据访问和公开所适用的许可。

测量、语言特征与时间关系

数据字典将三个结局标记为消极情绪 (SWB_nn)、积极情绪 (SWB_pp) 和生活满意度 (SWB_avg)，分别来源于中文版 PANAS 和 SWLS。原始 PANAS 的两个情绪分量表各包含十个题目，原始 SWLS 包含五个题目 (Diener et al., 1985; Watson et al., 1988)。本研究无法核实实际施测的题目措辞、情绪报告时段，以及生成给定分数所用的转换方式。保留样本中每个结局的取值范围均为 0 至 1。我们直接分析这些存储分数，并以其存储单位报告误差，不将其换算为原始问卷总分。

预测变量为从 AGENCY 至 Hate 的 120 列。根据采集说明，这些变量由每名参与者的聚合帖子计算而来，涉及简体中文 LIWC、道德基础、道德动机、文化价值和基本情绪等词典。说明中的词频定义为某一类别的词语计数除以文档总词数。本研究使用现成的聚合特征，未重新开展文本提取。词典的确切版本，以及 13 个代码 (A、B、C1 至 C10、D) 的语义映射不可用。另有 34 名保留参与者的 ind 值超过 1，与简单比例的解释不一致。这些特征在主分析中予以保留，并在一项预定敏感性分析中共同排除。标识符、时间戳、发帖量、问卷作答时长及其他问卷分数不作为预测变量。所有分析数值均完整且有限；没有常量预测变量，也未删除统计离群值。

在 1,037 条保留记录中，1,027 条记录的最后发帖时间戳数值大于问卷时间戳。将这一比较解释为时间顺序，需要假定二者采用共同的递增编码；现有文档未独立确证这一点。由于缺少原始帖子，我们无法将特征限制为问卷完成前的文本。因此，本研究估计的是聚合语言与存储问卷分数之间的回溯性个体间关联。原始帖子和题目反应的缺失，也使本研究无法评价奇偶文本一致性、问卷内部一致性，以及在匹配的语言与问卷时间窗中追踪个体内变化的能力。

模型开发与选择

分析计划在结构性数据审计后、模型比较前固定，但未进行公开预注册。以 20260923 为随机种子，按参与者进行随机划分，将 933 名参与者分配至开发集，104 名参与者分配至最终评估集。模型选择使用开发集内部的五折交叉验证。所有主分析模型共用这一划分，敏感性分析也保留原有参与者分配 (图 1)。该设计避免同一参与者跨越训练与评估分区，并允许在相同评估记录上开展配对比较。

每个训练折分别拟合中位数插补器、最小值—最大值输入缩放器，以及基于训练折均值和总体标准差的结局标准化。相应验证折直接应用这些已拟合转换，预测随后还原至存储分数单位。由于数据完整，插补器没有改变输入值。结局标准化使三个结局在共享输出损失中具有可比较的权重。将需要拟合的转换限定于训练折，可以避免验证观察影响预处理参数 (Kapoor & Narayanan, 2023)。

本研究比较训练均值基线、独立岭回归、独立随机森林、独立极端随机树、独立直方图梯度提升、共享输出随机森林、共享输出极端随机树，以及多任务弹性网。随机森林对随机化树的预测取平均，极端随机树则进一步随机化分裂阈值 (Breiman, 2001; Geurts et al., 2006)。共享输出森林对所



图 1: 参与者层面的分析流程。流程图描述给定记录的整理和分析，不表示招募阶段的样本流失。删除精确重复行后，为每名参与者保留数值型问卷时间戳最早的记录。开发集与留出集的参与者 ID 不重叠。所有需要拟合的预处理和主分析模型选择均限定于开发数据。

有结局使用共同的分裂结构，独立集成模型则为每个结局拟合一个回归器。多任务弹性网提供了共享稀疏结构的线性比较模型。主分析网格包含 42 个配置和 210 次复合折评估，其中每次独立目标拟合包含三个回归器。补充表 S1 和 S2 分别报告全部模型家族的表现和搜索设置。

模型选择以宏平均归一化均方根误差（RMSE）最小为准：将各结局的 RMSE 除以该训练折的结局标准差，再跨结局和折取平均。独立模型家族为每个结局分别选择超参数，共享模型家族则根据宏平均选择一个共同配置。在查看留出结果之前，我们确定了总体所选模型、最优共享模型、最优独立集成模型和最优树模型家族。森林均包含 256 棵树。主分析的固定搜索预算未因留出表现而扩展。由于独立与共享程序在共享结构和参数选择规则上均有区别，这一比较评价的是所选程序整体，而非单独操纵模型架构的效果。

评价、不确定性与后续分析

八类模型经开发集选择后，均在相同留出集上进行评价。Pearson 相关报告 Fisher- z 95% 置信区间和双侧检验；对总体所选模型的三个相关检验进行 Holm 校正。RMSE 区间采用 5,000 次参与者 bootstrap 重抽样的百分位区间，同时保留 R^2 和 Spearman 相关。两组预定比较分别评价所选模型相对训练均值，以及最优共享模型相对最优独立集成模型的表现。配对 RMSE 差值区间来自 5,000 次 bootstrap 重抽样；均方误差差值的双侧检验采用 10,000 次参与者内预测交换，并使用加一校正。Holm 校正覆盖全部六个“比较方式 $\times$ 结局”检验。Bootstrap 区间为逐点区间，不是同时区间。这些程序以已拟合模型和现有参与者划分为条件，预测交换检验还要求相应的可交换性假设；它们不包含在其他样本上重新拟合带来的不确定性，也不涵盖便利抽样框的影响。

三项预定敏感性分析分别使用每名参与者的最后一条不同记录、仅保留只出现一次的参与者，或删除 ind 和 13 个未映射代码。各项分析保留参与者分配，并在不重新调参的情况下重新拟合原

先选定的配置。另进行三次五折开发集交叉验证，以描述冻结配置下的表现波动。由于开发数据已经参与超参数选择，这些重复验证属于诊断，而非独立的嵌套验证。补充表 S3 和 S4 报告了相应结果。

本研究对开发集选出的树模型家族进行解释，在 933 名开发集参与者上计算树路径依赖的 TreeSHAP(Lundberg et al., 2020)。贡献值以存储分数单位表示，检验其加和重建后，按平均绝对值排序。各结局排名前十的特征取并集，共得到 14 个特征。在留出集中对每个特征单独进行 20 次置换，记录 RMSE 的变化。归因描述给定背景定义下特征对拟合预测的贡献，置换则检验破坏某个输入后误差如何变化。相关类别之间可能共享或替代信息；不同置换间的波动不等同于抽样置信区间。补充表 S5 和 S6 分别列出这些所选特征的全部已报告排名与置换诊断。

在查看主分析留出结果之后，另行固定探索性计划，测试覆盖更强正则化、平滑非线性回归、低维预测和较大叶节点森林的 22 个配置。原开发样本中的五个外层折，各自重新执行内部五折选择。在每个外层训练集中重新执行模型选择，可以处理给定搜索过程产生的选择性乐观偏差 (Cawley & Talbot, 2010)。随后在全部开发参与者上进行五折搜索，选定一个候选模型，并在此前已经查看过的留出集上评价。该扩展始终保留探索性地位，采用固定停止规则，并以相对原共享森林的外层宏平均归一化 RMSE 至少下降 1% 作为判断是否值得继续的启发式标准。完整方法与结果见补充表 S7 至 S10。

结果

预测关联与分数估计

保留样本包含 1,037 名参与者，其中开发集 933 人、留出集 104 人（表 1）。消极情绪与积极情绪的相关为 $r = -0.307$ ，与生活满意度的相关为 $r = -0.408$ ；积极情绪与生活满意度的相关为 $r = 0.458$ 。共享随机森林的开发集宏平均归一化 RMSE 最低 (0.9963)，独立随机森林紧随其后 (0.9965)，训练均值基线为 1.0016。选定共享森林的最小叶节点样本数为 15，每次分裂考虑全部预测变量。

表 1: 各分析分区的结局描述统计

结局	全部样本	开发集	留出集
NA	0.367 (0.160)	0.364 (0.159)	0.388 (0.169)
PA	0.543 (0.156)	0.545 (0.154)	0.524 (0.169)
LS	0.419 (0.210)	0.421 (0.211)	0.401 (0.205)

NA 为消极情绪，PA 为积极情绪，LS 为生活满意度。数值为存储单位下的均值（样本标准差）。全部样本 $n = 1,037$ ，开发集 $n = 933$ ，留出集 $n = 104$ 。完整保留样本中各结局的范围为 0–1；留出集不必覆盖完整范围。

在留出集中，选定共享森林与消极情绪的相关为 $r = 0.247$ ，95% CI [0.057, 0.419]；与积极情绪的相关为 $r = 0.284$ ，95% CI [0.097, 0.452]；与生活满意度的相关为 $r = 0.152$ ，95% CI [−0.042, 0.335]（表 2）。Holm 校正后的 p 值分别为 0.023、0.010 和 0.124。两种情绪的相关在该校正下可与零区分，生活满意度的估计则仍存在较大不确定性。本研究没有直接比较三个结局的相关系数。

表 2: 所选程序与基线的留出集表现

模型	结局	r [95% CI]	RMSE [95% CI]	R^2
共享 RF	NA	0.247 [0.057, 0.419]	0.166 [0.146, 0.186]	0.020
共享 RF	PA	0.284 [0.097, 0.452]	0.165 [0.143, 0.187]	0.040
共享 RF	LS	0.152 [−0.042, 0.335]	0.202 [0.181, 0.222]	0.015
独立 RF	NA	0.230 [0.039, 0.405]	0.165 [0.144, 0.185]	0.031
独立 RF	PA	0.325 [0.141, 0.487]	0.163 [0.141, 0.186]	0.057
独立 RF	LS	0.184 [−0.008, 0.364]	0.201 [0.180, 0.222]	0.025
训练均值	NA	未定义	0.169 [0.150, 0.190]	−0.021
训练均值	PA	未定义	0.170 [0.146, 0.192]	−0.016
训练均值	LS	未定义	0.205 [0.184, 0.225]	−0.009

NA 为消极情绪，PA 为积极情绪，LS 为生活满意度。RF 为随机森林，ET 为极端随机树，EN 为弹性网，HGB 为直方图梯度提升。 $n = 104$ 。共享 RF 由开发集选出。相关区间采用 Fisher z ，RMSE 区间来自 5,000 次参与者 bootstrap，保留存储分数单位。常量预测的相关未定义。 R^2 以留出集结局均值为参照，因此训练均值基线的 R^2 可以为负。

选定模型对消极情绪、积极情绪和生活满意度的 RMSE 分别为 0.166、0.165 和 0.202，相应 R^2 分别为 0.020、0.040 和 0.015。训练均值基线的 RMSE 分别为 0.169、0.170 和 0.205。因此，正相关伴随的是幅度较小的数值预测收益。不同模型家族之间也呈现出这一差别：在积极情绪上，多任务弹性网的描述性相关系数 ($r = 0.402$) 高于所选森林 ($r = 0.284$)，但二者的 RMSE 四舍五入后均为 0.165（补充表 S1）。主分析仍以开发集选出的森林为准。

所选模型减去训练均值基线的 RMSE 差值依次为 −0.0034、−0.0048 和 −0.0024（表 3；图 2）。两种情绪差值的逐点 bootstrap 区间均不包含零；但在六个预定比较范围内，对预测交换检验进行 Holm 校正后，三个结局的 p 值分别为 0.113、0.101 和 1.000。观察到的误差降幅较小，其证据没有达到预定的多重比较校正标准。逐点区间和校正后的检验对应不同的推断程序，不能将这些区间视为跨结局同时成立的模型优势证据。

共享结局与独立拟合的比较

共享森林在开发集中的微小优势，没有转化为低于独立森林的留出集 RMSE。共享模型减去独立模型的差值，在消极情绪、积极情绪和生活满意度上依次为 0.0009、0.0015 和 0.0011，三个逐点区间均包含零（表 3）。这些估计显示，两种所选程序在本样本中的表现接近，而不确定性同时允许任一方向上的小幅优势。因此，结果既未确立共享学习收益，也未证明两种程序等效。

表 3: 留出集预测误差的配对差值

比较	结局	ΔRMSE	95% CI	p (swap)	p (Holm)
所选模型 - 均值	NA	-0.0034	[-0.0064, -0.0006]	0.023	0.113
所选模型 - 均值	PA	-0.0048	[-0.0083, -0.0010]	0.017	0.101
所选模型 - 均值	LS	-0.0024	[-0.0074, 0.0024]	0.337	1.000
共享 - 独立	NA	0.0009	[-0.0018, 0.0039]	0.533	1.000
共享 - 独立	PA	0.0015	[-0.0007, 0.0036]	0.193	0.772
共享 - 独立	LS	0.0011	[-0.0021, 0.0044]	0.502	1.000

NA 为消极情绪, PA 为积极情绪, LS 为生活满意度。 $n = 104$ 。差值为第一模型减去第二模型, 负值有利于第一模型。所选/共享模型为共享 RF, 独立模型为独立 RF。区间为 5,000 次配对参与者 bootstrap 的逐点百分位区间。检验对 MSE 差值进行 10,000 次预测交换, Holm 校正覆盖全部六行。单位为存储分数单位。




图 2: 两组预定比较的留出集 RMSE 配对差值 ($n = 104$)。点表示第一模型减去第二模型的估计, 横线表示 5,000 次配对参与者 bootstrap 得到的逐点 95% 区间。负值有利于第一模型, 垂直线表示零差值。这些区间未作多重比较校正; 六个经 Holm 校正的预测交换检验另列于表 3。

语言类别对预测的贡献

各结局中平均绝对开发集 SHAP 贡献最高的特征有所不同（表 4）。消极情绪的前三项为 Sexual (0.0041)、C10 (0.0040) 和 C2 (0.0036)；积极情绪为 Sexual (0.0045)、We (0.0039) 和 Family (0.0030)；生活满意度为 Family (0.0061)、We (0.0056) 和 C10 (0.0052)。这些数值反映特征对拟合预测的贡献幅度，单位为存储分数单位。未映射代码保留原始标签；绝对贡献值不提供关联方向。

表 4: 各结局平均绝对 TreeSHAP 贡献最高的三个特征

结局	排名	特征	平均绝对 SHAP
NA	1	Sexual	0.0041
NA	2	C10 [†]	0.0040
NA	3	C2 [†]	0.0036
PA	1	Sexual	0.0045
PA	2	We	0.0039
PA	3	Family	0.0030
LS	1	Family	0.0061
LS	2	We	0.0056
LS	3	C10 [†]	0.0052

NA 为消极情绪，PA 为积极情绪，LS 为生活满意度。共享 RF，开发集 $n = 933$ 。数值使用存储结局单位及树路径依赖背景。[†] 表示语义映射尚未核实。幅度不表示方向、统计显著性或因果效应。

留出集扰动诊断产生的变化较小，且正负方向不一。对于积极情绪，置换开发集排名最高的 Sexual 后，RMSE 的平均变化仅为 0.000002，不同置换之间的标准差为 0.000544。对于生活满意度，Family 和 We 的平均变化分别为 0.001030 和 -0.000935。因此，开发集归因中的较高地位，并未一致对应于置换该特征后留出误差的增加。补充表 S6 报告了每个所选特征在各结局上的平均变化和置换波动。

敏感性分析与探索性扩展

使用最后记录时，所选模型对消极情绪、积极情绪和生活满意度的相关系数分别为 0.259、0.286 和 0.101。仅保留出现一次的参与者后，留出集剩余 85 人，相应相关系数为 0.303、0.301 和 0.173。删除 ind 和未映射代码后，相关系数为 0.301、0.268 和 0.125，RMSE 分别为 0.165、0.165 和 0.203。这些处理选择改变了点估计，但总体上仍呈现相关程度有限、分数估计收益较小的模式（补充表 S3）。重复开发集交叉验证的描述性汇总见补充表 S4。

探索性优化选出了最小叶节点样本数为 60、每次分裂考虑一半预测变量的独立森林。所选程序、固定的原共享森林和训练均值基线的外层宏平均归一化 RMSE 分别为 1.0006、1.0001 和 1.0007。所选程序的误差比原森林高 0.044%，未达到预定的 1% 改善标准。在此前已查看过的留出集上，相关系数依次为 0.245、0.332 和 0.164，RMSE 为 0.1661、0.1645 和 0.2023。积极情绪相对训练均值的探索性比较得到 Holm 校正后的 $p = 0.011$ ；与原森林比较时，各结局校正后的 p 值均为 1.000。这些重复使用留出集的结果与完整探索性搜索一并列于补充表 S7 至 S10，不替代主分析结果。

讨论

语言信息对幸福感评估的贡献

本研究的主要发现是，语言与情绪之间存在程度有限的关联，而这种关联转化为问卷分数估计的收益较小。这为使用心理语言类别评估幸福感的设想提供了数量上的限定。在本样本中，选定模型捕捉到了与两个情绪结局的线性共变，但加入语言特征后，大部分数值预测误差仍然存在。就相关区间而言，生活满意度的估计更不确定。因此，本研究的贡献在于评价给定表征和学习程序保留的信息；相较于单独依赖显著性检验，误差改善的幅度使其能够支持的评估主张更加具体。

积极情绪上弹性网与所选森林的对照，使这一差别更为直观：较大的相关系数，可以与几乎相同的 RMSE 同时出现。从数学上看，对预测值进行正比例缩放或平移，可以保持 Pearson 相关不变，却改变预测值与观察分数的距离。因此，能够追踪相对线性变化的模型，未必能准确重现个体分数的水平或离散程度。在本研究中，相对基线的小幅误差差值，是判断数值估计收益的直接证据。这一收益是否有用，则取决于具体决策、可解释的分数量尺及可接受的误差标准；本数据没有预先界定这些条件。

三个结局的不同估计引出了一个实质性假设：这些聚合语言类别可能更直接地反映情绪表达，而较少捕捉人们评价整体生活时所依据的标准。情绪与整体生活评价之间的概念区分，为检验这一可能性提供了依据 (Diener, 1984; Diener et al., 1985)。不过，效标信度、文本与问卷的时间匹配程度及抽样波动的差异，同样可能产生当前模式。由于本研究没有直接比较结局间的相关系数，实际施测工具的记录也不完整，结果支持的是分别验证各成分，而非认定情绪在本质上更容易预测。未来若能在不同结局之间控制语言暴露和测量质量，就更有可能区分这些解释。

表征、共享学习与模型解释

探索性优化的有限收益，使进入模型的信息成为值得进一步关注的问题。在保留相同聚合特征矩阵的情况下，改变正则化、平滑程度或维度，并未使嵌套开发集误差低于原森林。这一结果没有为继续沿已测试方向调参提供较强经验支持，同时保留了语言表征和效标质量这两种尚未解决的解释。封闭词汇与开放词汇方法可以捕捉不同的语言线索 (Eichstaedt et al., 2021)，每名参与者提供的语言量也会影响估计所依据的信息 (Kern et al., 2016)。在相同时间窗、效标和评估参与者上，比较固定类别与更丰富的语言表征，能够直接检验类别聚合是否丢失了有用信息。这比仅将当前误差归因于模型复杂度更有解释力。

共享输出比较为这一方法提供了第二个适用边界。幸福感结局之间的相关性构成了借用信息的理由，但有效共享需要相容的特征—结局关系。共同的树划分施加了其中一种具体的相容性约束 (Caruana, 1997; Koccev et al., 2007)。共享森林在开发集中的微小优势，以及在留出集上略高的误差，与“两种程序的真实差别较小，以致当前样本难以区分”的解释相容；它们也保留了另一种可能，即不同幸福感成分所依赖的语言关系只部分重合。独立模型为各结局分别选择参数，而共享模型使用共同设置，因此当前估计不能分离共享结构本身的影响。更有区分力的比较，应当匹配调参机会，并在新样本中检验可重复的、结局特定的差异。

归因结果定位了模型使用的特征，配套的扰动结果则为如何解释这些特征提供了必要的经验依据。**Sexual** 在积极情绪的开发集归因中排名第一，但将其置换后，留出误差的平均变化接近零。这样的差别可能反映特征冗余、拟合关系不稳定，或较小留出集诊断的敏感性有限；本研究不能据此确定具体原因。**TreeSHAP** 在给定背景定义下概括预测贡献 (Lundberg et al., 2020)，而改变算法输入与干预相应的现实行为并不相同 (Janzing et al., 2020)。两种分析回答的是关于预测器的互补问题，而不是“谈论某个话题是否会改变幸福感”。预测与因果解释需要不同的证据设计 (Shmueli, 2010)。

对于 **Family**、**We** 等类别，一个有价值的下一步是恢复其实际词表，并在原始帖子中区分自我描述、对他人的描述、引用和习惯性表达。中文词典匹配可能偏离语境含义的证据，使这一区分具有实际意义 (Zhao et al., 2016)。若某一类别的预测贡献经过语境核验后仍然存在，并能在新样本中重复，则可以进一步研究更具体的语言关联。若贡献消失，或在相关类别之间转移，则原有排名更适合被理解为拟合表征的特征。在开展这类实质研究之前，未映射代码首先需要获得可靠的词典映射。

从回溯性预测走向测量研究

若要将这些发现推进到监测用途，时间对齐是首要设计要求。本研究的语言特征可能包含问卷完成后的帖子，因而观察到的关联将一个时段不完全明确的表达记录与较早的报告联系起来。具有明确时间顺序的研究，需要在结局评估前界定语言窗口，并保留足以核验截止时间的帖子。此前通过 Facebook 预测抑郁医疗记录的研究，将语言置于相关医疗记录事件之前 (Eichstaedt et al., 2018)；可以借鉴的是这种时间安排，而不是将抑郁与幸福感视为相同构念。在此基础上，重复、匹配的语言窗口和问卷，才允许分别检验个体间差异和个体内变化。这两种用途应当作为不同目标进行评价。

问卷效标本身也需要明确的测量依据。核实实际题目、报告时段和分数转换方式，才能使误差具有可解释性，并检验效标信度。**PANAS** 可以采用不同的报告时段 (Watson et al., 1988)；对于 **SWLS**，时间稳定性与对真实生活变化的敏感性也是不同的测量要求 (Pavot & Diener, 1993)。语言估计需要重新建立这些性质的证据。**Park et al. (2015)** 采用的较广泛验证设计说明，与问卷的一致性还可以通过其他方法和时间检验来补充。对本研究而言，当前最直接的优先事项，是明确存储分数的含义，并检验时间匹配的语言是否能够为这些分数提供可靠的增量信息。

当前样本支持的是有范围限制的评价，尚不能推广至整体人群。数据来自便利样本，留出集包含 104 名参与者，且缺少用于考察亚组表现的人口学信息。不确定性区间以现有拟合模型和划分为条件；交叉验证训练样本之间存在重叠，也使折间波动不能替代基于独立样本的置信区间 (Varoquaux, 2018)。按参与者划分并在折内拟合预处理，可以处理重要的评估风险 (Kapoor & Narayanan, 2023)；跨人群、时期或平台的可迁移性，则需要通过独立招募的样本检验。开展这一评估之前，应冻结主分析程序，并针对目标用途明确所需精度和可接受误差。

现有聚合数据限制了对误差来源的进一步诊断。缺少题目反应，使给定效标的信度无法检验；缺少原始帖子，使语言时间窗和词汇覆盖无法重建；词典文档不完整，则限制了部分特征的解释。预定记录和特征敏感性分析考察了具体处理选择，却不能消除这些来源层面的不确定性。恢复相应

输入后，才能更有针对性地比较表征信息损失、效标噪声和时间不匹配的影响。这样的后续问题，比将小效应视为工具已可部署的证明，或视为语言幸福感评估的一般上限，都更加具体。

对于未来的评估用途，应依据语言估计相对直接报告增加了什么信息，以及其误差会产生什么后果来判断表现。例如，一项拟议应用可以检验：在直接测量较为稀疏时，语言估计能否改善某个预先界定的研究测量任务；这一收益需要在相应情境中实际证明。本研究未评价个体决策效用、总体代表性或具有实质意义的误差阈值。知情同意、隐私保护和参与者对敏感推断的控制同样属于设计要求，既有社交媒体健康预测研究也强调了这些问题 (Eichstaedt et al., 2018)。本研究为这一开发过程提供了参照，并明确了判断是否值得继续面向部署开展研究所需要的证据。

结论

微博的聚合心理语言特征包含与积极和消极情绪有关的有限回溯性信息，相对训练均值基线的分数估计收益较小。所选共享输出程序未确立相对独立森林的优势，开发集中归因较高的特征对留出误差的贡献也不一致。这些结果为给定表征提供了一个范围有限的预测参照。进一步开发评估工具，应首先明确分数解释和时间关系，再针对特定测量目的检验准确性、稳定性和可推广性。

声明

数据与代码可用性

分析代码和聚合结果可在公开项目仓库中获得，具有识别信息的仓库地址列于独立标题页。该公开仓库不包含参与者层面的记录、原始帖子、已拟合模型对象和逐人预测。数据保管者、访问条件、共享授权、数据集引用，以及匿名审稿链接或归档永久标识符，均待作者补充。本说明不代表原始数据所有者作出访问承诺。

伦理与作者声明

批准和知情同意信息来自原始采集说明，其是否涵盖本次二次使用仍需确认。作者身份、贡献、资助、利益冲突、致谢和最终审批，均待作者在独立标题页补充。

人工智能使用说明

根据项目记录，OpenAI Codex 协助了此前的分析代码开发与执行、文献检索、证据检查、图件准备和初稿撰写。ChatGPT 协助了本轮论文结构重整、中英文写作、针对性的来源复核、聚合结果呈现和文档检查。这些协助不构成人类作者审批。投稿之前，负责作者必须核实并批准数据来源、分析、解释、参考文献和相关声明。

参考文献

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

- Caruana, R. (1997). Multitask learning. *Machine Learning*, 28(1), 41–75. <https://doi.org/10.1023/A:1007379606734>
- Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11(70), 2079–2107. <https://jmlr.org/papers/v11/cawley10a.html>
- Diener, E. (1984). Subjective well-being. *Psychological Bulletin*, 95(3), 542–575. <https://doi.org/10.1037/0033-2909.95.3.542>
- Diener, E., Emmons, R. A., Larsen, R. J., & Griffin, S. (1985). The satisfaction with life scale. *Journal of Personality Assessment*, 49(1), 71–75. https://doi.org/10.1207/s15327752jpa4901_13
- Diener, E., Lucas, R. E., & Oishi, S. (2018). Advances and open questions in the science of subjective well-being. *Collabra: Psychology*, 4(1), 15. <https://doi.org/10.1525/collabra.115>
- Eichstaedt, J. C., Kern, M. L., Yaden, D. B., Schwartz, H. A., Giorgi, S., Park, G., Hagan, C. A., Tobolsky, V. A., Smith, L. K., Buffone, A., Iwry, J., Seligman, M. E. P., & Ungar, L. H. (2021). Closed- and open-vocabulary approaches to text analysis: A review, quantitative comparison, and recommendations. *Psychological Methods*, 26(4), 398–427. <https://doi.org/10.1037/met0000349>
- Eichstaedt, J. C., Smith, R. J., Merchant, R. M., Ungar, L. H., Crutchley, P., Preotiu-Pietro, D., Asch, D. A., & Schwartz, H. A. (2018). Facebook language predicts depression in medical records. *Proceedings of the National Academy of Sciences*, 115(44), 11203–11208. <https://doi.org/10.1073/pnas.1802331115>
- Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3–42. <https://doi.org/10.1007/s10994-006-6226-1>
- Jaidka, K., Giorgi, S., Schwartz, H. A., Kern, M. L., Ungar, L. H., & Eichstaedt, J. C. (2020). Estimating geographic subjective well-being from Twitter: A comparison of dictionary and data-driven language methods. *Proceedings of the National Academy of Sciences*, 117(19), 10165–10171. <https://doi.org/10.1073/pnas.1906364117>
- Janzing, D., Minorics, L., & Blöbaum, P. (2020). Feature relevance quantification in explainable AI: A causal problem. In S. Chiappa & R. Calandra (Eds.), *Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics* (Vol. 108, pp. 2907–2916). PMLR. <https://proceedings.mlr.press/v108/janzing20a.html>
- Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804. <https://doi.org/10.1016/j.patter.2023.100804>
- Kern, M. L., Park, G., Eichstaedt, J. C., Schwartz, H. A., Sap, M., Smith, L. K., & Ungar, L. H. (2016). Gaining insights from social media language: Methodologies and challenges. *Psychological Methods*, 21(4), 507–525. <https://doi.org/10.1037/met0000091>

- Kocev, D., Vens, C., Struyf, J., & Džeroski, S. (2007). Ensembles of multi-objective decision trees. In J. N. Kok, J. Koronacki, R. López de Mántaras, S. Matwin, D. Mladenič, & A. Skowron (Eds.), *Machine Learning: ECML 2007* (Vol. 4701, pp. 624–631). Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-540-74958-5_61
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67. <https://doi.org/10.1038/s42256-019-0138-9>
- Park, G., Schwartz, H. A., Eichstaedt, J. C., Kern, M. L., Kosinski, M., Stillwell, D. J., Ungar, L. H., & Seligman, M. E. P. (2015). Automatic personality assessment through social media language. *Journal of Personality and Social Psychology*, 108(6), 934–952. <https://doi.org/10.1037/pspp0000020>
- Pavot, W., & Diener, E. (1993). Review of the Satisfaction With Life Scale. *Psychological Assessment*, 5(2), 164–172. <https://doi.org/10.1037/1040-3590.5.2.164>
- Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3), 289–310. <https://doi.org/10.1214/10-STS330>
- Tausczik, Y. R., & Pennebaker, J. W. (2010). The psychological meaning of words: LIWC and computerized text analysis methods. *Journal of Language and Social Psychology*, 29(1), 24–54. <https://doi.org/10.1177/0261927X09351676>
- Varoquaux, G. (2018). Cross-validation failure: Small sample sizes lead to large error bars. *NeuroImage*, 180, 68–77. <https://doi.org/10.1016/j.neuroimage.2017.06.061>
- Watson, D., Clark, L. A., & Tellegen, A. (1988). Development and validation of brief measures of positive and negative affect: The PANAS scales. *Journal of Personality and Social Psychology*, 54(6), 1063–1070. <https://doi.org/10.1037/0022-3514.54.6.1063>
- Yarkoni, T., & Westfall, J. (2017). Choosing prediction over explanation in psychology: Lessons from machine learning. *Perspectives on Psychological Science*, 12(6), 1100–1122. <https://doi.org/10.1177/1745691617693393>
- Zhao, N., Jiao, D., Bai, S., & Zhu, T. (2016). Evaluating the validity of simplified Chinese version of LIWC in detecting psychological expressions in short texts on social network services. *PLOS ONE*, 11(6), e0157947. <https://doi.org/10.1371/journal.pone.0157947>